

Trabajo Práctico Final

Introducción

El rendimiento académico de los estudiantes está atravesado por muchos factores. Algunas variables están directamente vinculadas con la trayectoria escolar previa, como las notas obtenidas durante el año o la cantidad de reprobaciones anteriores. Otras describen aspectos familiares, sociales y personales que también pueden estar asociados al desempeño: el tiempo dedicado al estudio, las ausencias, el apoyo escolar, el apoyo familiar, el tiempo libre, las salidas con amigos o el deseo de continuar estudios superiores.

En este trabajo nos interesa estudiar el rendimiento de estudiantes en un curso de estadística. En particular, queremos conocer qué factores se asocian a una mejor o peor nota al final del curso. El objetivo no es solamente construir un modelo con buena capacidad predictiva, sino también interpretar qué variables parecen estar relacionadas con mejores o peores resultados académicos.

Como es esperable, las notas obtenidas durante distintos momentos del año están correlacionadas entre sí. Un estudiante con buen desempeño en el primer o segundo período probablemente también tenga un mejor desempeño en la nota final. Por ese motivo, en una primera etapa se trabajará bajo la premisa de que no pueden utilizarse las notas previas `nota1` y `nota2`. Esto obliga a realizar un análisis exploratorio más cuidadoso y a pensar qué información aporta el resto de las variables.

El objetivo

El conjunto de datos `notas_estadistica.csv` contiene información sobre los estudiantes de un curso de estadística e incluye variables escolares, familiares, sociales y personales. Las notas se encuentran en una escala de 0 a 10.

Las variables disponibles son:

Variable	Descripción
<code>escuela</code>	Escuela a la que asiste el estudiante.
<code>sexo</code>	Sexo del estudiante.
<code>edad</code>	Edad del estudiante.
<code>domicilio</code>	Tipo de domicilio del estudiante: urbano o rural.
<code>tamano_familia</code>	Tamaño del grupo familiar: hasta 3 integrantes o más de 3 integrantes.
<code>convivencia_padres</code>	Situación de convivencia de los padres: juntos o separados.
<code>educacion_madre</code>	Nivel educativo de la madre.
<code>educacion_padre</code>	Nivel educativo del padre.
<code>trabajo_madre</code>	Ocupación de la madre.
<code>trabajo_padre</code>	Ocupación del padre.
<code>motivo_escuela</code>	Motivo principal por el que el estudiante eligió la escuela.
<code>tutor</code>	Persona responsable o tutora del estudiante.
<code>tiempo_viaje</code>	Tiempo de viaje desde el hogar hasta la escuela.
<code>tiempo_estudio</code>	Tiempo semanal dedicado al estudio.
<code>reprobaciones_previas</code>	Cantidad de materias o cursos reprobados previamente.
<code>apoyo_escolar</code>	Indica si el estudiante recibe apoyo educativo extra de la escuela.
<code>apoyo_familiar</code>	Indica si el estudiante recibe apoyo educativo de la familia.
<code>clases_pagadas</code>	Indica si el estudiante toma clases pagadas extra.

Variable	Descripción
<code>actividades</code>	Participación en actividades extracurriculares.
<code>jardin_infantes</code>	Indica si el estudiante asistió a jardín de infantes.
<code>quiere_superior</code>	Indica si el estudiante quiere continuar estudios superiores.
<code>internet</code>	Acceso a internet en el hogar.
<code>pareja</code>	Indica si el estudiante está en una relación de pareja.
<code>relacion_familiar</code>	Calidad de las relaciones familiares, medida en una escala ordinal.
<code>tiempo_libre</code>	Tiempo libre después de la escuela, medido en una escala ordinal.
<code>salidas_amigos</code>	Frecuencia con la que el estudiante sale con amigos, medida en una escala ordinal.
<code>alcohol_semana</code>	Consumo de alcohol en días de semana, medido en una escala ordinal.
<code>alcohol_finde</code>	Consumo de alcohol durante el fin de semana, medido en una escala ordinal.
<code>salud</code>	Estado de salud actual reportado por el estudiante.
<code>ausencias</code>	Cantidad de ausencias escolares.
<code>nota1</code>	Nota del primer período.
<code>nota2</code>	Nota del segundo período.
<code>nota3</code>	Nota final del curso.

La variable respuesta principal será `nota3`. El objetivo final del trabajo es construir modelos de regresión lineal normal bayesiana que permitan estudiar qué variables se asocian con la nota final de los estudiantes.

En una primera parte, deberán ajustar modelos para `nota3` sin utilizar `nota1` ni `nota2`. Para ello, será necesario realizar un buen análisis exploratorio de datos, estudiar la relación entre las variables disponibles y proponer un subconjunto razonable de predictores. No es necesario utilizar todas las variables: se espera que justifiquen cuáles incorporan, cuáles descartan y por qué.

En una segunda parte, deberán ajustar nuevos modelos que incorporen información de las notas previas. Comparen los resultados con los modelos anteriores y discutan qué cambia en la interpretación de los parámetros y como se impacta la capacidad predictiva del modelo.

Se sugiere abordar, entre otros, los siguientes interrogantes:

- ¿Qué variables parecen estar más asociadas con la nota final cuando no se usan las notas previas?
- ¿Qué patrones aparecen en el análisis exploratorio de datos?
- ¿Qué subconjunto de variables resulta razonable para construir un modelo interpretable?
- ¿Cómo cambia el modelo cuando se incorpora `nota1`?
- ¿Qué ocurre al incorporar también `nota2`?
- ¿Es preferible un modelo con una o dos notas previas? ¿Por qué?
- ¿Las notas previas explican casi toda la variación relevante o siguen apareciendo otros factores?

Para ello, se recomienda que se tengan en consideración las siguientes pautas generales que hacen a un análisis bayesiano:

- Análisis exploratorio de datos
- Propuesta y ajuste de modelos
 - Descripción matemática
 - Elicitación de los *priors*
 - Pruebas predictivas *a priori*
 - Ajuste del modelo

- Evaluación de la convergencia de las cadenas de Markov
 - Exploración de la distribución *a posteriori* de los parámetros
 - Pruebas predictivas *a posteriori*
 - Evaluación del ajuste del modelo
 - Interpretación de parámetros
- Comparación de modelos
 - Análisis final y conclusión

Se recomienda fuertemente que se haga uso de diferentes visualizaciones para comunicar los resultados de las diferentes etapas del análisis y que se propongan y evalúen un mínimo de tres modelos.

La presentación deberá incluir:

- Introducción clara al problema
- Definición de las preguntas de investigación
- Descripción del conjunto de datos a utilizar
- Análisis exploratorio de los datos
- Fundamentación y análisis de los modelos propuestos
- Comparación de modelos
- Hallazgos, resultados y conclusiones

Adicionalmente, construyan un modelo para predecir la probabilidad de que un estudiante apruebe el curso. Para ello, definan una nueva variable binaria:

$$\text{aprobado} = \begin{cases} 1 & \text{si } \text{nota3} \geq 5 \\ 0 & \text{si } \text{nota3} < 5 \end{cases}$$

En este caso, la variable respuesta ya no es continua sino binaria.

Comparen este análisis con el modelo para la nota final: ¿los factores asociados a obtener una mayor nota son los mismos que los asociados a aprobar el curso? ¿Cambia la interpretación de los coeficientes? ¿Qué ventajas y limitaciones tiene transformar la nota final en una variable de aprobación o desaprobación?

! Pautas para la entrega

La presentación debe tener un máximo de 20 *slides*.